


Usando la Estadística para predicción económica

Introducción a las técnicas de Regresión

Valentina Muñoz Urango

APERTURE - Semillero de Investigación

2026



¿Qué es la Econometría?



*Entonces, si la econometría quiere **cuantificar relaciones** entre variables económicas. . .*

¿Cómo lo hace?

¿Con qué herramientas lo hace?

La mayoría de sus técnicas parten de un mismo fundamento: **la Regresión**.

Fundamentos de la Regresión



La Regresión

Definición

Una regresión es una técnica estadística que estudia cómo se relacionan una variable de interés con una o más variables que explican su comportamiento, con el objetivo de **estimar el valor esperado** de la primera, dado un conjunto de valores de las segundas.

Ejemplo de regresión: Educación y Salario

Supongamos que realizamos un estudio y recolectamos datos. Tenemos la base CPS1985 (*Current Population Survey*, 1985), con información de 534 trabajadores estadounidenses:

Trabajador	wage (USD/hora)	education (años)
1	5.10	8
2	4.95	9
3	6.67	12
5	4.00	12
5	7.50	12
⋮	⋮	⋮


Nos surgen dos preguntas

Preguntas

- ¿Cuánto cambia el salario de un trabajador a medida que tiene más años de educación?
- ¿Será que la educación es un factor importante que explica bien el monto salarial?

De la pregunta al modelo

Queremos modelar el **salario** dados los **años de educación**. Aquí entra la regresión: una herramienta que relaciona estas dos variables.



¿Qué busca la regresión?

- La regresión busca una **función** que describe cómo varía el **promedio** de Y a medida que cambia X .

No responde

¿Cuánto será exactamente el salario de esta persona?

Eso depende de muchísimos factores y no puedo observarlos todos.


Sí responde

¿Cuánto cambia, en promedio, el salario a medida que aumentan los años de estudio?

Es una pregunta sobre la tendencia, no sobre un individuo.

Selecciono solo **algunos de los factores que puedo observar** (aquí, la educación) y miro qué tanto influyen.

La recta de regresión



La recta pasa por el “centro” de la nube de puntos: estima el salario **promedio esperado** dado un nivel de educación, no el valor puntual de cada trabajador.

¿Por qué se llama “regresión”?

Curiosidad histórica

Francis Galton analizaba las alturas de hijos y las alturas promedio de sus padres.

- Hijos de padres muy altos (o muy bajos) tendían a ser más altos (o más bajos) que el promedio poblacional...
- ...pero **no tanto** como sus padres.
- Es decir: los valores extremos tendían a “**regresar**” hacia la media poblacional en la siguiente generación.

Con el tiempo, “regresión” pasó a usarse como sinónimo del estudio de la relación funcional entre dos o más variables.

Forma general

$$Y = f(X_1, X_2, \dots, X_k; \theta) + \varepsilon$$


- Y : variable dependiente (respuesta)
- $X_1, \dots, X_k$: variables independientes (regresoras)
- $f(\cdot)$: forma funcional (lineal, logística, etc.)
- θ : parámetros a estimar
- ε : término de error

Antes de estimar: elegir el modelo

Para estimar los parámetros, primero debo **elegir la forma** en que voy a modelar mis variables, es decir, la función f :

$$Y = f(X; \theta) + \varepsilon$$

Y esa elección depende de la **naturaleza de la variable respuesta** Y .



¿Qué podemos modelar en economía con regresión?

Basta con identificar una **variable de interés** y otras que ayuden a explicar su comportamiento:

- Cómo cambia la **demanda** de un producto ante cambios en su **precio**.
- Cómo se relaciona el **ingreso** de una persona con su educación y experiencia.
- Cómo la **inversión**, el **consumo** y el **empleo** se relacionan con el crecimiento económico.
- La relación entre las características de una empresa/cliente y la **probabilidad de incumplimiento** de un crédito.

En resumen

La regresión permite pasar de una afirmación económica **cualitativa** a una relación **cuantitativa** estimable con datos reales.

Nos concentraremos en dos modelos: **MRLM** y **Regresión Logística**.

Modelo de Regresión Lineal Múltiple (MRLM)



Regresión lineal: Concepto

Caso particular de regresión en el que:

Respuesta continua

Y_i toma valores en los **reales**: $Y_i \in \mathbb{R}$.

Por ejemplo, el salario por hora.

Relación lineal

Se asume que la relación entre Y y las predictoras es **lineal**: se puede representar mediante una **función lineal**.

Empecemos por el caso más sencillo: **una sola variable explicativa**.

Regresión lineal simple: Modelo y notación

Cuando estudiamos la relación entre una variable respuesta y **una sola** variable explicativa, tenemos una **regresión lineal simple**:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

- Y_i : variable **respuesta**, la que queremos estudiar.
- X_i : variable **explicativa** (predictora).
- β_0 : **intercepto**, el valor esperado de Y_i cuando la predictora es 0.
- β_1 : **pendiente**, cuánto cambia (en promedio) Y_i cuando la predictora aumenta una unidad.
- ε_i : **error**, todo aquello que afecta a Y_i pero no estamos incluyendo en el modelo.

Siguiendo con el ejemplo: Salario y Educación

El modelo con **solamente** la educación sería:

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Educación}_i + \varepsilon_i$$

Símbolo	En el ejemplo
Y_i	Salario por hora del trabajador i
X_i	Años de educación del trabajador i
β_0	Salario esperado de alguien con 0 años de educación
β_1	Cambio en el salario por cada año adicional de educación
ε_i	Todo lo demás que afecta el salario y no está en el modelo

MRLM: Más de una predictora

¿Y si creemos que Y_i se relaciona con **más de una** variable? También las incluimos en el modelo: es el **Modelo de Regresión Lineal Múltiple** (MRLM).

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + \varepsilon_i$$

En nuestro ejemplo

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Educación}_i + \beta_2 \text{Experiencia}_i + \varepsilon_i$$

MRLM: Interpretación de los parámetros

Con más variables y más parámetros, la interpretación cambia un poco. En el modelo

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Educación}_i + \beta_2 \text{Experiencia}_i + \varepsilon_i$$

- β_1 : cuánto cambia **en promedio** el salario por cada año adicional de educación, **manteniendo constante** la experiencia.
- β_2 : cuánto cambia en promedio el salario por cada año adicional de experiencia, manteniendo constante la educación.

Ceteris paribus

En Economía, a esto se le llama “*ceteris paribus*”: **manteniendo todo lo demás constante**.

MRLM: Notación matricial

Por cada observación tenemos una ecuación:

$$Y_1 = \beta_0 + \beta_1 X_{11} + \cdots + \beta_k X_{1k} + \varepsilon_1$$

$$\vdots$$

$$Y_n = \beta_0 + \beta_1 X_{n1} + \cdots + \beta_k X_{nk} + \varepsilon_n$$

Son muchas ecuaciones, y computacionalmente es más fácil manejar **matrices**. El modelo en forma matricial es:

$$Y = X\beta + \varepsilon$$

MRLM: Componentes del modelo matricial

$$Y = X\beta + \varepsilon$$

$$Y_{n \times 1} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} X_{n \times (k+1)} = \begin{pmatrix} 1 & X_{11} & \cdots & X_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & \cdots & X_{nk} \end{pmatrix} \beta_{(k+1) \times 1} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_k \end{pmatrix} \varepsilon_{n \times 1} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- X : matriz de **características** (normalmente, nuestra base de datos).
- Y : vector de **observaciones** de la respuesta.
- β : vector de **parámetros**.
- ε : vector de **errores**.

MRLM: Supuestos del modelo

¿Qué son?

Condiciones que necesitamos para que las conclusiones que sacamos sean **confiables**.

Supuesto sobre las predictoras: No multicolinealidad

Idea

Las variables que metemos al modelo **no deben ser lo mismo entre ellas**.

Ejemplo

Queremos explicar de nuevo el salario, pero ahora incluyendo también la **Edad**:

$$\text{Salario}_i = \beta_0 + \beta_1 \text{Educación}_i + \beta_2 \text{Experiencia}_i + \beta_3 \text{Edad}_i + \varepsilon_i$$

Es muy posible que **Edad** y **Experiencia** estén relacionadas: la regresión no podrá distinguir bien el aporte de cada una.

Formalmente se pide que no haya multicolinealidad **perfecta**: las columnas de X deben ser linealmente independientes.

Supuestos sobre el error

Supuesto	Expresión	¿Qué permite?
Independencia	$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, i \neq j$	Cada observación aporta información separada.
Media cero	$E[\varepsilon_i] = 0$	En promedio, la regresión no se equivoca.
Varianza constante	$\text{Var}(\varepsilon_i) = \sigma^2$	La variabilidad del error es la misma para cualquier valor de X .
Normalidad	$\varepsilon_i \sim N(\cdot, \cdot)$	Facilita la inferencia.

$$\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$


MRLM: Estimación de los parámetros

Mínimos Cuadrados (MCO)

Busca la recta que quede **lo más cerca posible de los datos**: minimiza la distancia entre el dato real y el estimado por la regresión (el **residuo**).

Como los residuos pueden ser positivos o negativos, se **elevan al cuadrado**:

$$\min_{\beta} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$



Máxima Verosimilitud

Busca los valores de los parámetros que hacen que los datos que observamos sean **los más probables**.

MRLM: El estimador

Ambos métodos nos dan el **mismo resultado**:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

Y ese es el valor de los betas.

MRLM: Comentarios finales

- **No multicolinealidad:** la necesitamos para poder calcular la **inversa** $(X^T X)^{-1}$ que aparece en el estimador.
- **“Lineal” = lineal en los parámetros:** las predictoras pueden estar transformadas (X^2 , $\log X$, $X_1 X_2$), pero los parámetros van con exponente 1.
- **No sirve para extrapolar:** la regresión aprende de los datos que tenemos, así que sus predicciones son razonables dentro de ese rango. Fuera de él no conocemos la relación.
- **Sensible a valores atípicos:** como MCO minimiza errores al cuadrado, los *outliers* pueden influir mucho sobre $\hat{\beta}$. Es importante revisar los datos.

Regresión Logística



Motivación

En el modelo anterior Y_i era **continua**. Pero, ¿qué pasa si ahora queremos estudiar...

- ¿un cliente **pagó** su crédito o no?
- ¿un producto sale **defectuoso** o no?

Solo hay dos posibles respuestas: **Sí** o **No**.

Variable binaria

$$Y_i = \begin{cases} 1 & \text{éxito} \\ 0 & \text{fracaso} \end{cases}$$

¿Qué hacemos?

El problema

Como Y_i solo toma los valores 0 y 1, ya **no tiene sentido** preguntar *¿cuánto vale Y en promedio?*

En nuestro problema

¿Cuál es la probabilidad de que el **cliente pague el crédito**, dadas unas características que conozco?


$$\theta_i = P(Y_i = 1 \mid x_i)$$

Un problema con el modelo anterior

Si usamos el modelo lineal para una probabilidad, puede dar valores **menores que 0** o **mayores que 1**. Eso no tiene sentido.

¿Cómo lo solucionamos?

Con una **función de enlace** que haga que el resultado quede **siempre entre 0 y 1**.



Notación: cómo se arma el modelo


$$\theta_i = P(Y_i = 1 \mid \mathbf{x}_i)$$

Combinamos las características **linealmente**, igual que antes, pero conectándolas con una **función de enlace** $g(\cdot)$:

$$g(\theta_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}$$

¿Qué hace el logit?


El logit convierte una probabilidad en un número real en **dos pasos**:



Probabilidad θ_i	0.01	0.10	0.50	0.90	0.99
Chances	0.01	0.11	1	9	99
Logit	-4,6	-2,2	0	2.2	4.6

Probabilidades que estaban **apretadas entre 0 y 1** ahora se reparten por **toda la recta real**, con $\theta_i = 0,5$ en el centro (logit = 0).

La forma del logit



Cerca de 0 y de 1 el logit se **dispara**. Su inversa, la función logística, es esta misma curva con los ejes intercambiados.

Ejemplo de modelo

Queremos la probabilidad de que un cliente **pague** su crédito, dados su **ingreso** y su **nivel de endeudamiento**:

$$\ln\left(\frac{\theta_i}{1 - \theta_i}\right) = \beta_0 + \beta_1 \text{Ingreso}_i + \beta_2 \text{Endeudamiento}_i$$

Donde

- $Y_i = 1$ si el cliente i paga el crédito, $Y_i = 0$ si no.
- $\theta_i = P(Y_i = 1 \mid \text{Ingreso}_i, \text{Endeudamiento}_i)$: cada cliente tiene su **propio** θ_i .

Ojo: la interpretación cambia

Hay que tener en cuenta que...

Ahora el coeficiente **no** representa directamente cuánto aumenta la probabilidad, porque la relación **ya no es lineal**. No se interpreta igual que en el modelo anterior.

La interpretación se da en términos de la **razón de probabilidades**:

$$\psi(x_i) = \frac{\theta_i}{1 - \theta_i} = \textit{Chances}$$

Es justo el argumento dentro del logaritmo: compara la probabilidad de que **ocurra** el evento con la de que **no ocurra**.

Regresión Logística: Supuestos del modelo

Al igual que antes, necesitamos supuestos para que nuestras conclusiones sean **confiables estadísticamente**.

- **Independencia:** las observaciones son independientes. Si tenemos 500 personas, el resultado de una no depende directamente del de otra.
- **Relación lineal con el logit:** las predictoras se relacionan de forma aproximadamente lineal con el $\text{logit}(\theta_i)$.
- **No multicolinealidad:** cada variable aporta información que se puede distinguir de la de las demás.

¿Y los supuestos sobre el error?

Regresión lineal

Y puede tomar **muchos valores**, y usamos el término de error ε para representar **lo que el modelo no puede explicar**.

Regresión logística

Y solo puede ser 0 o 1, y modelamos **directamente la probabilidad** de que ocurra el evento. Por eso no necesitamos poner un error.

No es que no haya incertidumbre

Al modelar la probabilidad, el valor θ_i **ya incluye la incertidumbre**.

Estimación de los parámetros

Ya no usamos MCO

Ya no buscamos una **recta** que se acerque a los datos: ahora modelamos **probabilidades**.

Máxima Verosimilitud

Buscamos los β que **expliquen mejor lo que observamos**.

$$L(\beta) = \prod_{i=1}^n \theta_i^{y_i} (1 - \theta_i)^{1-y_i}, \quad \hat{\beta} = \arg \max_{\beta} L(\beta)$$

No es fácil de despejar

θ_i depende de β de forma **no lineal**, así que no hay solución algebraica: se resuelve con **métodos numéricos** (en R: `glm()`).

Regresión Logística: Comentarios finales

Interpretación de coeficientes: vía su exponencial (chances)

$$\exp(\hat{\beta}_j) = \frac{\psi(x_j + 1)}{\psi(x_j)}$$

- $\exp(\hat{\beta}_j) > 1$: aumentan las chances de éxito.
- $\exp(\hat{\beta}_j) < 1$: disminuyen las chances de éxito.
- $\exp(\hat{\beta}_j) = 1$: la variable no tiene efecto.

Cambio porcentual: $(\exp(\hat{\beta}_j) - 1) \times 100\%$

El modelo entrega **probabilidades** ($\hat{\theta}_i \in (0, 1)$), no clases; convertir a clasificación binaria requiere elegir un **umbral de corte**.

Evaluación de Modelos




¿Qué queremos saber?

Una vez ajustado el modelo, necesitamos saber:



Veremos algunas **métricas de evaluación** para estos modelos.

Métricas de evaluación: el mapa




Regresión lineal: descomposición de la variabilidad

La **variabilidad total** está dada por la diferencia entre el dato y la media:

$$Y_i - \bar{Y} \quad (\text{flecha gris})$$

Se parte en dos:

- **SSR** (regresión): $\hat{Y}_i - \bar{Y}$. Lo que el modelo **explica**.
- **SSE** (error): $Y_i - \hat{Y}_i$. Lo que el modelo **no explica**.



$$\text{Total} = \text{explicado} + \text{error}$$

Descomposición de la varianza

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{\text{SST}} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{\text{SSR}} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{\text{SSE}}$$

SST: variabilidad total

SSR: explicada por el modelo


SSE: error

Coeficiente de determinación R^2


El R^2 responde:

¿Qué proporción de la variabilidad total de Y logra explicar mi modelo?

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}, \quad 0 \leq R^2 \leq 1$$



R^2 **cercano a 1**: los puntos están pegados a la recta; el modelo explica casi toda la variabilidad.



R^2 **cercano a 0**: los puntos están dispersos; el modelo explica poco.

R^2 ajustado


Es una **mejora** del R^2 que **penaliza** **agregar más variables** al modelo:

$$R^2_{adj} = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

n : observaciones, k : predictoras.

¿Por qué?

El R^2 **nunca baja** al agregar variables, aunque no aporten nada. El R^2_{adj} sí puede bajar.



Gráfica ilustrativa ($n = 30$).

Regresión logística: la matriz de confusión

Sirve para evaluar **qué tan bien el modelo acierta la clasificación**: compara lo que el modelo **predijo** con lo que **realmente ocurrió**.

		Predicho	
		Predice 1	Predice 0
Real	Real = 1	VP verdadero positivo	FN falso negativo
	Real = 0	FP falso positivo	VN verdadero negativo

■ **Aciertos** (diagonal): el modelo coincide con la realidad.

■ **Errores**: el modelo se equivoca.

Los cuatro casos

Con el ejemplo del crédito ($Y = 1$: el cliente paga; $Y = 0$: no paga):

Verdadero positivo (VP)

Predice **1** y realmente es **1**.
Se predijo que pagaría, y pagó.

Falso positivo (FP)

Predice **1** pero en realidad era **0**.
Se predijo que pagaría, pero no pagó.

Verdadero negativo (VN)

Predice **0** y realmente es **0**.
Se predijo que no pagaría, y no pagó.

Falso negativo (FN)

Predice **0** pero en realidad era **1**.
Se predijo que no pagaría, pero sí pagó.

Tasa de clasificación correcta (TCC)

Indica qué **proporción de todas las predicciones fueron acertadas**:

$$TCC = \frac{VP + VN}{VP + VN + FP + FN}$$

- **Numerador**: los aciertos (la diagonal).
- **Denominador**: todas las observaciones, n .

	Pred. 1	Pred. 0
Real 1	VP	FN
Real 0	FP	VN

Ejemplo práctico 1: MRLM



Ejemplo 1: Brecha salarial de género

Datos simulados de **500 empleados** (fuente: Coursera, *Econometrics: Methods and Applications*).

Variable	Descripción
LogWage (Y)	Logaritmo natural del salario anual (índice con mediana = 100)
Female	1 si es mujer, 0 si es hombre
Age	Edad en años (20–70)
Educ	Nivel educativo, de 1 (menor) a 4 (mayor). Dummies DE2, DE3, DE4; Educ = 1 es la referencia
Parttime	1 si trabaja medio tiempo, 0 si trabaja tiempo completo

Se modela $\log(\text{Wage})$ porque los salarios están sesgados a la derecha.

Pregunta

¿Existe una brecha salarial entre hombres y mujeres? Si existe, ¿se debe al género en sí o a otras características (edad, educación, jornada)?

Los modelos

Modelo simple: brecha bruta

$$\log(\text{Wage}_i) = \beta_0 + \beta_1 \text{Female}_i + \varepsilon_i$$

Modelo múltiple: brecha ajustada

$$\begin{aligned} \log(\text{Wage}_i) = & \beta_0 + \beta_1 \text{Female}_i + \beta_2 \text{Age}_i \\ & + \beta_3 \text{DE2}_i + \beta_4 \text{DE3}_i + \beta_5 \text{DE4}_i + \beta_6 \text{Parttime}_i + \varepsilon_i \end{aligned}$$

Como Y está en logaritmo: $\% \Delta \text{Wage} \approx 100 \hat{\beta}$; el valor exacto es $100 (e^{\hat{\beta}} - 1)$.

Ajuste de los modelos (R)

```
wage <- read.table("DataMRLM.txt", header = TRUE, sep = "\t")

# Modelo simple: brecha bruta
mod_simple <- lm(LogWage ~ Female, data = wage)
summary(mod_simple)

# Modelo multiple: brecha ajustada
mod_mult <- lm(LogWage ~ Female + Age + factor(Educ) + Parttime,
               data = wage)
summary(mod_mult)
```

Métricas de evaluación (R)

```
# R2 y R2 ajustado  
s1 <- summary(mod_simple); s2 <- summary(mod_mult)  
c(s1$r.squared, s1$adj.r.squared)  
c(s2$r.squared, s2$adj.r.squared)
```

Modelo	R^2	R^2_{adj}
Simple	0.0726	0.0708
Múltiple	0.7161	0.7127

Interpretación económica: la brecha salarial

Brecha bruta (simple)

$$\hat{\beta}_1 = -0,2506$$

Las mujeres ganan aproximadamente **25 % menos** que los hombres.

Brecha ajustada (múltiple)

$$\hat{\beta}_1 = -0,0308$$

Con las demás variables constantes, la diferencia baja a **3.0 %** y **deja de ser estadísticamente significativa**.

- Gran parte de la brecha *bruta* no se debe al género en sí, sino a diferencias entre grupos en características que también afectan el salario (edad, educación, jornada).

Solo con el género, el modelo explica el **7.3 %** de la variabilidad del log-salario; con las demás variables, el **71.6 %**.

Las demás variables

Variable	$\hat{\beta}$	Efecto en el salario
Age (por año adicional)	0,0304	+3,1 %
Educ = 2 (vs. 1)	0,1706	+18,6 %
Educ = 3 (vs. 1)	0,3805	+46,3 %
Educ = 4 (vs. 1)	0,7655	+115,0 %
Parttime (vs. tiempo completo)	-0,3659	-30,6 %
Female	-0,0308	-3,0 %

- Más edad y más educación se asocian con **salarios más altos**; trabajar medio tiempo, con **salarios más bajos**.

Ejemplo práctico 2: Regresión Logística



Ejemplo 2: Incumplimiento de pago (*Default*)

Base `Default` (paquete `ISLR`): **10,000 clientes** de tarjetas de crédito.

Variable	Descripción
<code>default_bin</code> (Y)	1 si el cliente incumplió (dejó de pagar), 0 si no
<code>balance</code>	Saldo de deuda del cliente
<code>income</code>	Ingreso del cliente
<code>student_bin</code>	1 si es estudiante, 0 si no

Muestra dividida en **entrenamiento** (70 %, 7,000 obs.) y **prueba** (30 %, 3,000 obs.)

Pregunta

¿Qué características de un cliente se asocian con una mayor probabilidad de incumplir?

Los modelos

Aquí el “éxito” es **incumplir**: $\theta_i = P(Y_i = 1 \mid x_i)$ es la probabilidad de que el cliente i incumpla.

Modelo simple

$$\text{logit}(\theta_i) = \beta_0 + \beta_1 \text{balance}_i$$

Modelo múltiple

$$\text{logit}(\theta_i) = \beta_0 + \beta_1 \text{balance}_i + \beta_2 \text{income}_i + \beta_3 \text{student}_i$$

Los coeficientes se interpretan en términos de **chances**: $e^{\hat{\beta}_j}$ es el factor por el que se multiplican.

Ajuste de los modelos (Python)

```
import statsmodels.api as sm
import statsmodels.formula.api as smf
from sklearn.model_selection import train_test_split

# Cargar la base Default (paquete ISLR)
default = sm.datasets.get_rdataset("Default", "ISLR").data

# Convertir las variables Yes/No en variables 0/1
default["default_bin"] = (default["default"] == "Yes").astype(int)
default["student_bin"] = (default["student"] == "Yes").astype(int)

# Dividir en entrenamiento (70%) y prueba (30%)
train, test = train_test_split(default, test_size=0.3, random_state=123,
                                stratify=default["default_bin"])

# Modelo simple:  $\text{logit}(\theta) = b_0 + b_1 \cdot \text{balance}$ 
mod_simple = smf.glm("default_bin ~ balance", data=train,
                     family=sm.families.Binomial()).fit()

# Modelo multiple: se agregan income y student_bin
mod_mult = smf.glm("default_bin ~ balance + income + student_bin",
                   data=train, family=sm.families.Binomial()).fit()
```

Métricas de evaluación (Python)

```
from sklearn.metrics import confusion_matrix, accuracy_score

# Se evalua cada modelo con el conjunto de PRUEBA
for nombre, mod in [("simple", mod_simple), ("multiple", mod_mult)]:
    # Probabilidad estimada de incumplir; si supera 0.5 se predice 1
    pred = (mod.predict(test) > 0.5).astype(int)
    print(nombre)
    # Matriz de confusion: [[VN, FP], [FN, VP]]
    print(confusion_matrix(test["default_bin"], pred))
    # TCC = (VP + VN) / total: proporcion de aciertos
    print("TCC:", accuracy_score(test["default_bin"], pred))
```

Modelo simple: TCC = 0,9730

	Pred. No	Pred. Sí
Real No	2891 (VN)	9 (FP)
Real Sí	72 (FN)	28 (VP)

Modelo múltiple: TCC = 0,9753

	Pred. No	Pred. Sí
Real No	2892 (VN)	8 (FP)
Real Sí	66 (FN)	34 (VP)

Interpretación económica: los coeficientes

Modelo múltiple, en términos de **chances** (*ceteris paribus*):

Variable	$\hat{\beta}$	$e^{\hat{\beta}}$	p -valor
balance	0,0058	1,0058	$< 0,001$
income	$4,2 \times 10^{-6}$	1,000004	0,667
student_bin	-0,7234	0,485	0,010

- **Balance:** Más endeudamiento implica mucho más riesgo de impago.
- **Ingreso:** no es significativo.
- **Estudiante:** a igual balance e ingreso, las chances de incumplir de un estudiante son $\approx 51,5\%$ menores.

Cuando las observaciones no son independientes en el tiempo

Muchas variables económicas (PIB, inflación, desempleo, tasas de interés, ventas) se observan **a lo largo del tiempo**: sus observaciones suelen estar relacionadas con las de periodos anteriores.

En ese caso, el MRLM puede no ser la herramienta adecuada (supuesto de **independencia** de los errores). Suele ser más conveniente usar **modelos de series de tiempo** u otras técnicas que tengan en cuenta la dinámica de las variables.

¡Gracias!

¿Preguntas?



Asistencia