


Usando la Estadística para predicción económica

Introducción a las técnicas de Regresión

Valentina Muñoz Urango

APERTURE - Semillero de Investigación

2026



¿Qué es la Econometría?

Definición

"La econometría es la rama de la economía que se encarga de contrastar la teoría económica con los métodos cuantitativos y estadísticos con el fin de probar hipótesis que permitan determinar o no la validez de los postulados económicos; así mismo, se encarga de estimar y pronosticar fenómenos económicos." (Iglesias Ibarra y Fernández Rangel, 2022)

Econometría = Teoría Económica + Matemáticas + Estadística

- La **teoría** nos dice qué relaciones esperar.
- Las **matemáticas** dan el lenguaje formal para expresarlas.
- La **estadística** permite validarlas con datos reales.

La mayoría de sus técnicas parten de un mismo fundamento: **la Regresión**.

*Entonces, si la econometría quiere **cuantificar relaciones** entre variables económicas. . .*

¿Cómo lo hace?

¿Con qué herramientas lo hace?

Esa es la pregunta que iremos respondiendo, empezando por la **Regresión**.

Fundamentos de la Regresión



La Regresión

Definición

Una regresión es una técnica estadística que estudia cómo se relacionan una variable de interés con una o más variables que explican su comportamiento, con el objetivo de **estimar el valor esperado** de la primera, dado un conjunto de valores de las segundas.

De forma intuitiva: dados datos de X e Y , la regresión busca la función que mejor describe cómo varía el **promedio** de Y a medida que cambia X .

Idea clave

No se busca predecir el valor exacto de Y para cada observación, sino **entender la tendencia** de la relación entre las variables.

¿Por qué se llama "regresión"?

Curiosidad histórica

Francis Galton analizaba las alturas de hijos varones y las alturas promedio de sus padres.


- Hijos de padres muy altos (o muy bajos) tendían a ser más altos (o más bajos) que el promedio poblacional...
- ...pero **no tanto** como sus padres.
- Es decir: los valores extremos tendían a **regresar**" hacia la media poblacional en la siguiente generación.

Con el tiempo, "regresión" pasó a usarse como sinónimo del estudio de la relación funcional entre dos o más variables.

Ejemplo de regresión: Educación y Salario

Datos: CPS1985 (*Current Population Survey*, 1985) — salario por hora y años de educación de 534 trabajadores estadounidenses.

Pregunta: ¿cuánto cambia, en promedio, el salario por cada año adicional de educación?



La recta pasa por el "centro" de la nube de puntos: estima el salario **promedio esperado** condicional a cada nivel de educación, no el valor puntual de cada trabajador.

Forma general

$$Y = f(X_1, X_2, \dots, X_k; \theta) + \varepsilon$$

- Y : variable dependiente (respuesta)
- $X_1, \dots, X_k$: variables independientes (regresoras)
- $f(\cdot)$: forma funcional (lineal, logística, etc.)
- θ : parámetros a estimar
- ε : término de error

De forma más rigurosa

$$E[Y \mid X] = f(X; \theta)$$

La regresión modela el **promedio condicional** de Y dado X ; ε es lo que el modelo no puede explicar.

Tipos de Regresión

La elección del modelo depende de **la naturaleza de la variable respuesta** Y (continua, binaria, de conteo, categórica).

Tipo	$f(X; \theta)$	Y típica	Descripción
Lineal	$\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$	Continua	Relación aditiva directa
Logística	$\frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots)}}$	Binaria (0/1)	Combinación lineal $\rightarrow$ probabilidad
Poisson	$e^{\beta_0 + \beta_1 X_1 + \dots}$	Conteos	Valores esperados no negativos
No paramétrica	Sin forma fija	Cualquiera	Se adapta a los datos

Todos comparten la forma $Y = f(X; \theta) + \varepsilon$: cambia $f(\cdot)$ y los supuestos sobre ε (o sobre Y).

¿Qué podemos modelar en economía con regresión?

Basta con identificar una **variable de interés** y otras que ayuden a explicar su comportamiento:

- Cómo cambia la **demanda** de un producto ante cambios en su **precio**.
- Cómo se relaciona el **ingreso** de una persona con su educación y experiencia.
- Cómo la **inversión**, el **consumo** y el **empleo** se relacionan con el crecimiento económico.
- La relación entre las características de una empresa/cliente y la **probabilidad de incumplimiento** de un crédito.

En resumen

La regresión permite pasar de una afirmación económica **cualitativa** a una relación **cuantitativa** estimable con datos reales.

Nos concentraremos en dos modelos: **MRLM** y **Regresión Logística**.

Modelo de Regresión Lineal Múltiple (MRLM)



MRLM: Concepto

Caso particular de regresión en el que la relación entre Y y las X_j se asume **lineal en los parámetros**.

Considere el caso en el cual se desea modelar la variabilidad total de una variable respuesta de interés, en función de sus relaciones lineales con dos o más variables predictoras, formuladas simultáneamente en un único modelo."

(González Álvarez, 2025)

Idea intuitiva

Con **una sola** predictora no podemos saber si el efecto observado se debe realmente a esa variable, o a otra característica que suele venir junto con ella. El MRLM incluye **varias predictoras a la vez** para "separar" sus efectos: al estimar β_j , el modelo mantiene **fijas** (controla por) las demás variables, de modo que β_j refleja solo el cambio en Y atribuible a X_j .

Ej.: ¿el mayor consumo de un hogar se debe al **ingreso**, o a que ese hogar también tiende a ser más grande? El MRLM controla por tamaño del hogar (y precios) para aislar el efecto *puro* del ingreso.

MRLM: Notación

Escalar (para n observaciones):

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + \varepsilon_i, \quad i = 1, \dots, n$$

- β_0 : intercepto β_j : efecto *ceteris paribus* de X_j sobre Y
- ε_i : lo que las predictoras no logran explicar

Matricial:

$$Y = X\beta + \varepsilon$$

$$Y_{n \times 1} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} \quad X_{n \times (k+1)} = \begin{pmatrix} 1 & X_{11} & \cdots & X_{1k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & \cdots & X_{nk} \end{pmatrix} \quad \beta_{(k+1) \times 1} = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_k \end{pmatrix} \quad \varepsilon_{n \times 1} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

MRLM: Supuestos del modelo

Sobre las predictoras:

- **No multicolinealidad perfecta:** columnas de X LI $\iff \det(X^T X) \neq 0$.

Sobre el error:

$$\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$$

Encierra **cuatro** supuestos:

- **Media cero:** $E[\varepsilon_i] = 0$
- **Normalidad:** permite pruebas de hipótesis e IC
- **Homocedasticidad:** $\text{Var}(\varepsilon_i) = \sigma^2$ constante
- **Independencia:** $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, i \neq j$

MRLM: Estimación de los parámetros

¿Cómo hallamos $\hat{\beta}$ a partir de los datos?

- **MCO:** minimiza la suma de errores al cuadrado.
- **Máxima Verosimilitud:** maximiza la probabilidad de haber observado los datos, dado el supuesto sobre ε .

Bajo los supuestos anteriores, ambas técnicas llegan al mismo estimador:

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

¿Por qué necesitábamos no-multicolinealidad?

Si las columnas de X no son LI, $X^T X$ no es invertible: **no existe solución única** para $\hat{\beta}$.

MRLM: Comentarios finales

- **Interpretación:** $\hat{\beta}_j$ = cambio esperado en Y por un aumento unitario en X_j , *ceteris paribus*.
- **No sirve para extrapolar:** solo es confiable dentro del rango observado de las predictoras.
- **"Lineal" $\neq$ relación lineal entre variables:** es lineal en β ; se pueden incluir X^2 , $\log(X)$, $X_1 X_2$ y el modelo sigue siendo MRLM.
- **Sensible a atípicos:** como MCO minimiza errores al cuadrado, los *outliers* pueden tener mucha influencia sobre $\hat{\beta}$.

Regresión Logística



Motivación

En el MRLM, Y era **continua**. Pero es muy común que Y sea **binaria**:

- ¿Un cliente paga o no un crédito?
- ¿Un producto sale defectuoso o no?

El cambio de enfoque

No tiene sentido preguntar "¿cuánto vale Y en promedio?" ($Y \in \{0, 1\}$). Lo que sí tiene sentido: **¿qué tan probable es que ocurra $Y = 1$** , dadas ciertas características?

El problema deja de ser modelar Y y pasa a ser modelar $\theta_i = P(Y_i = 1 \mid x_i)$.

Regresión Logística: Concepto

Definición

Modelo de regresión para variables respuesta **binarias**, en el cual la probabilidad de éxito $\theta_i = P(Y_i = 1 \mid x_i)$ se relaciona con las predictoras a través de una combinación lineal, transformada mediante la función de enlace **logit**, de forma que las probabilidades estimadas queden acotadas entre 0 y 1.

Ejemplo guía: riesgo de incumplimiento de crédito en n empresas — cada una con su **propio** θ_i (no un único θ para todas).

Notación: cómo se arma el modelo

$$Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(\theta_i), \quad \theta_i = P(Y_i = 1 \mid \mathbf{x}_i)$$

Queremos que θ_i dependa de $\mathbf{x}_i$: combinamos las características **linealmente**, igual que en el MRLM. Pero $\theta_i \in [0, 1]$, así que conectamos con una **función de enlace** $g(\cdot)$:

$$g(\theta_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik}$$

¿Por qué una función de enlace?

Si $g(\theta_i) = \theta_i$ (como en el MRLM), el predictor lineal podría tomar valores fuera de $[0, 1]$ — inválido para una probabilidad.


La función de enlace logit

$$\text{logit}(\theta_i) = \ln\left(\frac{\theta_i}{1-\theta_i}\right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$$

$\psi(x_i) = \frac{\theta_i}{1-\theta_i}$: **razón de probabilidades** (odds ratio).

El logit **estira** $(0, 1)$ hacia toda la recta real; al ser invertible, se despeja θ_i y se obtiene la función **logística**:

$$\theta_i = \frac{e^{z_i}}{1 + e^{z_i}}, \quad z_i = \beta_0 + \beta_1 x_{i1} + \dots$$



Regresión Logística: Supuestos del modelo

- **Distribución Bernoulli:** cada $Y_i \sim \text{Bernoulli}(\theta_i)$.
- **Independencia:** $Y_1, \dots, Y_n$ independientes entre sí.
- **Linealidad en el logit:** $\ln(\psi(x_i))$ es lineal en las predictoras.
- **No multicolinealidad:** columnas de X LI.

¿Por qué no hay supuestos sobre el error?

Y_i es Bernoulli, y ahí la varianza depende completamente de la media:

$$\text{Var}(Y_i) = \theta_i(1 - \theta_i)$$

Conocido θ_i , la varianza queda determinada — no hay un error "separado" que controlar, como sí lo había en el MRLM.

Estimación de los parámetros

No existe fórmula cerrada para $\hat{\beta} \rightarrow$ se usa **Máxima Verosimilitud**.

$$L(\beta) = \prod_{i=1}^n \theta_i^{y_i} (1 - \theta_i)^{1-y_i}, \quad \hat{\beta} = \arg \max_{\beta \in \mathbb{R}^p} L(\beta)$$

- θ_i depende de β de forma **no lineal** $\rightarrow$ no hay solución algebraica.
- Se resuelve **numéricamente** (Newton-Raphson / IRLS) — en R: `glm()`.

Con n grande:

$$\hat{\beta} \overset{\text{aprox}}{\sim} N_p(\beta, V), \quad V = I^{-1}$$

$\rightarrow$ permite errores estándar, IC y pruebas de hipótesis, como en el MRLM.

Regresión Logística: Comentarios finales

Interpretación de coeficientes: vía su exponencial (odds ratio)

$$\exp(\hat{\beta}_j) = \frac{\psi(x_j + 1)}{\psi(x_j)}$$

- $\exp(\hat{\beta}_j) > 1$: aumentan las chances de éxito.
- $\exp(\hat{\beta}_j) < 1$: disminuyen las chances de éxito.
- $\exp(\hat{\beta}_j) = 1$: la variable no tiene efecto.

Cambio porcentual: $(\exp(\hat{\beta}_j) - 1) \times 100\%$

El modelo entrega **probabilidades** ($\hat{\theta}_i \in (0, 1)$), no clases; convertir a clasificación binaria requiere elegir un **umbral de corte**.

Evaluación, Comparación y Ejemplos Prácticos



Evaluación y Comparación de Modelos: Concepto

En la práctica se plantean **varios modelos candidatos** (distintas variables, transformaciones, formas funcionales).

Dos preguntas distintas

- **Evaluación:** ¿qué tan bien se ajusta un modelo a los datos?
- **Comparación/selección:** ¿cuál de los modelos candidatos deberíamos preferir?

La estadística usa **algoritmos de selección** (exploran subconjuntos de variables) y **métricas** que resumen qué tan bueno es un modelo — algunas generales, otras específicas al tipo de Y .

Métricas de evaluación

Para el MRLM — descomposición de la varianza:

- $SST = \sum_i (Y_i - \bar{Y})^2$: variabilidad **total**.
- $SSR = \sum_i (\hat{Y}_i - \bar{Y})^2$: variabilidad **explicada**.
- $SSE = \sum_i (Y_i - \hat{Y}_i)^2$: variabilidad **no explicada**.

$$SST = SSR + SSE$$

$$R^2 = \frac{SSR}{SST} \in [0, 1] \quad \cdot \quad \text{Prueba } F: H_0 : \beta_1 = \dots = \beta_k = 0 \quad \cdot \quad \text{Prueba } t: H_0 : \beta_j = 0$$

Para la regresión logística — clasificación (sobre el conjunto de *prueba*):

- **Matriz de confusión** (VP, FN, FP, VN)
- **TCC** = $\frac{VP + VN}{n}$ — cuidado con clases desbalanceadas
- **Curva ROC y AUC**: evalúa en **todos** los umbrales a la vez

Criterios de comparación y selección de modelos

Penalizan la **complejidad**: un modelo con más variables casi siempre ajusta "mejor", pero no queremos sobreajuste.

- R^2 **ajustado**: $R_{aj}^2 = 1 - \frac{SSE/(n-p)}{SST/(n-1)}$ — solo sube si la nueva variable "vale la pena".
- C_p **de Mallows**: $C_p = \frac{SSE_p}{\widehat{MSE}_{\text{completo}}} - (n - 2p)$. Se buscan modelos con $C_p \approx p$.
- $PRESS_p$: mide predicción sobre observaciones **no usadas** para estimar:
 $PRESS_p = \sum_i e_{(i)}^2$.

Ejemplo práctico: MRLM — Brecha salarial de género

Datos: 500 empleados. $Y = \log(\text{Wage}_i)$. Predictoras: Female, Age, Educ (dummies), Parttime.

Modelo simple: $\log(\text{Wage}_i) = \beta_0 + \beta_1 \text{Female}_i + \varepsilon_i$

Modelo múltiple:

$\log(\text{Wage}_i) = \beta_0 + \beta_1 \text{Female}_i + \beta_2 \text{Age}_i + \beta_3 \text{DE2}_i + \beta_4 \text{DE3}_i + \beta_5 \text{DE4}_i + \beta_6 \text{Parttime}_i + \varepsilon_i$

```
wage <- read.table("DataMRLM.txt", header = TRUE, sep = "\t")
wage$LogWage <- log(wage$Wage)

# Modelo simple: solo genero
mod_simple <- lm(LogWage ~ Female, data = wage)

# Modelo multiple: genero + edad + educacion + jornada
mod_mult <- lm(LogWage ~ Female + Age + factor(Educ) + Parttime,
               data = wage)
summary(mod_mult)
```

Ejemplo práctico: MRLM — Resultados e interpretación

Modelo simple	Estimate	t value	Pr(> t)
Female	-0,2506	-6,24	< 0,001

Modelo múltiple	Estimate	t value	Pr(> t)
Female	-0,0308	-1,27	0,206
Age	0,0304	24,27	< 0,001
Parttime	-0,3659	-11,81	< 0,001

Interpretación económica: la brecha bruta (22.2 % menos salario para mujeres) se reduce a 3.1 % y **deja de ser significativa** al controlar por edad, educación y jornada — gran parte de la diferencia observada se explica por otras características, no por el género en sí.

Comparación: R^2_{aj} sube de 0.071 a 0.713; el C_p del modelo simple es mucho mayor que su p (le faltan variables relevantes).

Ejemplo práctico: Regresión Logística — Riesgo de default

Datos: Default (ISLR), 10,000 clientes (3.3 % incumple). $Y = \text{default}$. Predictoras: balance, income, student.

Modelo simple: $\text{logit}(\theta_i) = \beta_0 + \beta_1 \text{balance}_i$

Modelo múltiple: $\text{logit}(\theta_i) = \beta_0 + \beta_1 \text{balance}_i + \beta_2 \text{income}_i + \beta_3 \text{student}_i$

```
import statsmodels.formula.api as smf

# Modelo simple: solo balance de deuda
mod_simple = smf.logit("default ~ balance", data=datos).fit()

# Modelo multiple: balance + ingreso + si es estudiante
mod_mult = smf.logit("default ~ balance + income + student",
                    data=datos).fit()

print(mod_mult.summary())
```

Ejemplo práctico: Regresión Logística — Evaluación

```
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, roc_auc_score

train, test = train_test_split(datos, test_size=0.3, random_state=1)
mod = smf.logit("default ~ balance + income + student",
               data=train).fit()

prob = mod.predict(test)
pred = (prob > 0.5).astype(int)
confusion_matrix(test["default"], pred)
roc_auc_score(test["default"], prob)
```

Interpretación económica: cada dólar adicional de deuda multiplica las chances de incumplir por $\exp(\hat{\beta}) = 1,0055$; ser estudiante **reduce** las chances en $\sim 52\%$; income no resulta significativo.

Comparación (conjunto de prueba): TCC sube de 97.30 % a 97.53 %; AUC de 0.939 a 0.940 — mejora real pero pequeña: el balance de deuda ya es un predictor muy fuerte por sí solo.

Cuando las observaciones no son independientes en el tiempo

Muchas variables económicas (PIB, inflación, desempleo, tasas de interés, ventas) se observan **a lo largo del tiempo**: sus observaciones suelen estar relacionadas con las de periodos anteriores.

En ese caso, el MRLM puede no ser la herramienta adecuada (supuesto de **independencia** de los errores). Suele ser más conveniente usar **modelos de series de tiempo** u otras técnicas que tengan en cuenta la dinámica de las variables.

Referencias

- González Álvarez, N. (2025). *Notas de Clase Estadística III 3009137. Cap. 2: MRLM*. U. Nacional de Colombia.
- Cardona Jiménez, J. (2026). *Estadística II* [notas de clase]. U. Nacional de Colombia.
- Iglesias Ibarra, A. J., y Fernández Rangel, J. A. (2022). *Introducción a la econometría*. Fundación Universitaria del Área Andina.
- Vidakovic, B. (2011). Regression. En *Statistics for Bioengineering Sciences*. Springer.
- Universidad Erasmus de Róterdam. *Erasmus Econometrics* [curso en línea]. Coursera.

¡Gracias!

¿Preguntas?



Asistencia