

Regresión Lineal Simple y Múltiple — Brecha Salarial de Género

Parte práctica: Introducción a la Econometría — Modelos de Regresión

September, 2026

Contents

1	Datos	1
1.1	Descripción de la base	1
1.2	¿Qué queremos analizar?	2
2	Transformación de Wage a log(Wage)	2
3	Ajuste del modelo: Regresión Lineal Simple	3
3.1	Análisis del modelo	4
3.2	Métricas de evaluación	4
4	Regresión Lineal Múltiple (MRLM)	4
4.1	Análisis del modelo	5
4.2	Supuesto de no multicolinealidad	5
4.3	Métricas de evaluación	6
5	Comparación de modelos	6

1 Datos

1.1 Descripción de la base

Usamos un conjunto de datos simulados de **500 empleados**. **Fuente:** Coursera. Econometrics: Methods and Applications. El dataset es el siguiente:

```
wage <- read.table("DataMRLM.txt", header = TRUE, sep = "\t")
str(wage)
```

```
## 'data.frame':    500 obs. of  10 variables:
## $ Observ. : int  1 2 3 4 5 6 7 8 9 10 ...
## $ Wage    : int  66 34 70 47 107 188 123 57 42 200 ...
## $ LogWage : num  4.19 3.53 4.25 3.85 4.67 ...
## $ Age     : int  49 42 42 38 54 54 47 39 25 59 ...
## $ Female  : int  0 1 1 0 1 1 1 1 1 0 ...
## $ Educ    : int  1 1 1 1 1 1 1 1 1 1 ...
## $ DE2     : int  0 0 0 0 0 0 0 0 0 0 ...
## $ DE3     : int  0 0 0 0 0 0 0 0 0 0 ...
## $ DE4     : int  0 0 0 0 0 0 0 0 0 0 ...
## $ Parttime: int  1 1 1 0 1 0 0 1 0 0 ...
```

Variable	Descripción
Wage (Y)	Salario anual, indexado de forma que la mediana sea 100
LogWage	Logaritmo natural de Wage (variable respuesta)
Age	Edad, en años (20–70)
Female	1 si es mujer, 0 si es hombre
Educ	Nivel educativo (categórica: 1, 2, 3, 4 — de menor a mayor)
DE2, DE3, DE4	Variables dummy para Educ = 2, 3, 4 (Educ = 1 es la categoría de referencia)
Parttime	1 si el empleo es de medio tiempo (máx. 3 días/semana), 0 si es de tiempo completo


1.2 ¿Qué queremos analizar?

Queremos **comparar el salario entre hombres y mujeres** (brecha salarial de género). Analizaremos las diferencias en promedio y también si estas diferencias se deben a otras características que también afectan el salario (edad, educación, tipo de jornada) con un MRLM.

2 Transformación de Wage a log(Wage)

Es muy importante que antes de modelar hagamos un análisis descriptivo y observemos cómo se comportan los datos. En el histograma de la derecha podemos observar que los salarios están sesgados a la derecha. Transformamos con el logaritmo para que la distribución sea más simétrica (cercano al supuesto de normalidad que exige el MRLM).

```
par(mfrow = c(1, 2))
hist(wage$Wage, main = "Wage (sin transformar)",
     xlab = "Índice salarial", col = "lightblue")
hist(wage$LogWage, main = "log(Wage)",
     xlab = "log(índice salarial)", col = "lightgreen")
```




Cuando la variable respuesta está en logaritmo, el coeficiente de una variable categórica (como el género) se interpreta aproximadamente como **el cambio porcentual** en el salario asociado a esa característica (se puede verificar por propiedades de los logaritmos):

$$\% \Delta \text{Wage} \approx 100 \times \hat{\beta}_{\text{Female}}$$

También, El logaritmo suele estabilizar la varianza, ayudando a cumplir el supuesto de homocedasticidad.

```
boxplot(LogWage ~ Female, data = wage,
        names = c("Hombres", "Mujeres"),
        ylab = "log(Wage)", col = c("lightblue", "lightpink"),
        main = "Distribución de log(Wage) por género")
```



3 Ajuste del modelo: Regresión Lineal Simple

Empecemos ajustando un modelo simple, para luego compararlo con un modelo con más variables. Para este primero, modelamos el salario en función únicamente del género. Esto nos da la **brecha salarial bruta** (sin ajustar).

$$\log(\text{Wage}_i) = \beta_0 + \beta_1 \cdot \text{Female}_i + \varepsilon_i$$

```
mod_simple <- lm(LogWage ~ Female, data = wage)
summary(mod_simple)
```

```
##
## Call:
## lm(formula = LogWage ~ Female, data = wage)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.09562 -0.30262 -0.03683  0.30338  1.41397
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   4.73362    0.02434  194.453  < 2e-16 ***
## Female        -0.25060    0.04013   -6.245  9.1e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4327 on 498 degrees of freedom
```

```
## Multiple R-squared:  0.07262,    Adjusted R-squared:  0.07076
## F-statistic:      39 on 1 and 498 DF,  p-value: 9.101e-10
```

3.1 Análisis del modelo

```
beta_female_simple <- coef(mod_simple)["Female"]
gap_exacto <- (exp(beta_female_simple) - 1) * 100

cat("Brecha salarial bruta (aproximada):", round(beta_female_simple * 100, 2), "%\n")
```

```
## Brecha salarial bruta (aproximada): -25.06 %
```

```
cat("Brecha salarial bruta (exacta, con exp()):", round(gap_exacto, 2), "%\n")
```

```
## Brecha salarial bruta (exacta, con exp()): -22.17 %
```

Se concluye que, las mujeres de esta muestra ganan, en promedio, cerca de 22.2% menos que los hombres. Nos falta ver si esta brecha se debe a otras diferencias entre ambos grupos.

3.2 Métricas de evaluación

```
r2 <- summary(mod_simple)$r.squared
r2_aj <- summary(mod_simple)$adj.r.squared
mse <- mean(residuals(mod_simple)^2)

cat("R^2:", round(r2, 4), "\n")
```

```
## R^2: 0.0726
```

```
cat("R^2 ajustado:", round(r2_aj, 4), "\n")
```

```
## R^2 ajustado: 0.0708
```

```
cat("MSE:", round(mse, 4), "\n")
```

```
## MSE: 0.1865
```

Con solo el género como predictora, el modelo explica apenas 7.3% de la variabilidad del log-salario (El género por sí solo no captura las verdaderas razones de las diferencias salariales). Veamos qué pasa si añadimos edad, educación y tipo de jornada.

4 Regresión Lineal Múltiple (MRLM)

Añadimos Age, Educ (como variable categórica, vía sus dummies DE2, DE3, DE4) y Parttime como predictoras adicionales.

$$\log(\text{Wage}_i) = \beta_0 + \beta_1 \text{Female}_i + \beta_2 \text{Age}_i + \beta_3 \text{DE2}_i + \beta_4 \text{DE3}_i + \beta_5 \text{DE4}_i + \beta_6 \text{Parttime}_i + \varepsilon_i$$

```
mod_mult <- lm(LogWage ~ Female + Age + factor(Educ) + Parttime, data = wage)
summary(mod_mult)
```

```
##
```

```
## Call:
```

```
## lm(formula = LogWage ~ Female + Age + factor(Educ) + Parttime,
```

```
##     data = wage)
```

```
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.70087 -0.15260  0.00123  0.15881  0.79566
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.317969   0.051398  64.555 < 2e-16 ***
## Female        -0.030837   0.024353  -1.266   0.206
## Age           0.030368   0.001251  24.269 < 2e-16 ***
## factor(Educ)2  0.170586   0.027037   6.309 6.24e-10 ***
## factor(Educ)3  0.380458   0.029277  12.995 < 2e-16 ***
## factor(Educ)4  0.765463   0.035423  21.609 < 2e-16 ***
## Parttime      -0.365900   0.030979 -11.811 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2406 on 493 degrees of freedom
## Multiple R-squared:  0.7161, Adjusted R-squared:  0.7127
## F-statistic: 207.3 on 6 and 493 DF,  p-value: < 2.2e-16
```

4.1 Análisis del modelo

```
beta_female_mult <- coef(mod_mult)["Female"]
gap_exacto_mult <- (exp(beta_female_mult) - 1) * 100

cat("Brecha salarial AJUSTADA (aproximada):", round(beta_female_mult * 100, 2), "%\n")
```

```
## Brecha salarial AJUSTADA (aproximada): -3.08 %
```

```
cat("Brecha salarial AJUSTADA (exacta):", round(gap_exacto_mult, 2), "%\n")
```

```
## Brecha salarial AJUSTADA (exacta): -3.04 %
```

```
cat("P-valor de Female en el modelo multiple:", round(summary(mod_mult)$coefficients["Female", 4],
  ↪ 4), "%\n")
```

```
## P-valor de Female en el modelo multiple: 0.206
```

Ahora que añadimos edad, educación y tipo de jornada (si medio tiempo o más), el coeficiente de **Female** se reduce (de -25.1% a apenas -3.1%) y **deja de ser estadísticamente significativo** (p-valor 0.206).

Podemos decir entonces que gran parte de la brecha salarial “bruta” que veíamos en el modelo simple no se debe al género en sí, sino a que, en esta muestra, las mujeres tienden a tener características distintas a las de los hombres (por ejemplo, mayor incidencia de trabajo de medio tiempo) que también afectan el salario.

Las variables Age y niveles de educación (DE2, DE3, DE4) y Parttime son significativas, lo que nos dice que mayor edad y mayor nivel educativo se asocian con salarios más altos, mientras que trabajar medio tiempo se asocia con salarios más bajos (consistente).

4.2 Supuesto de no multicolinealidad

```
X <- model.matrix(mod_mult)[, -1]
vif_manual <- sapply(colnames(X), function(v) {
  f <- as.formula(paste0("~", v, "~ ."))
  r2_v <- summary(lm(f, data = as.data.frame(X)))$r.squared
  1 / (1 - r2_v)
})
```

```
print(round(vif_manual, 3))
```

```
##           Female           Age factor(Educ)2 factor(Educ)3 factor(Educ)4
##           1.191           1.584           1.238           1.228           1.225
##           Parttime
##           1.699
```

Todos los VIF están muy por debajo de 5, por lo que no hay evidencia de multicolinealidad problemática entre las predictoras.

4.3 Métricas de evaluación

```
r2_m <- summary(mod_mult)$r.squared
r2_aj_m <- summary(mod_mult)$adj.r.squared
mse_m <- mean(residuals(mod_mult)^2)

cat("R^2:", round(r2_m, 4), "\n")
```

```
## R^2: 0.7161
```

```
cat("R^2 ajustado:", round(r2_aj_m, 4), "\n")
```

```
## R^2 ajustado: 0.7127
```

```
cat("MSE:", round(mse_m, 4), "\n")
```

```
## MSE: 0.0571
```

Este modelo explica mucho más la variabilidad de los datos.

4.3.1 Descomposición de la varianza (SST, SSR, SSE)

```
sst <- sum((wage$LogWage - mean(wage$LogWage))^2)
ssr <- sum((fitted(mod_mult) - mean(wage$LogWage))^2)
sse <- sum(residuals(mod_mult)^2)

cat("SST:", round(sst, 2), "\n")
```

```
## SST: 100.56
```

```
cat("SSR:", round(ssr, 2), "\n")
```

```
## SSR: 72.01
```

```
cat("SSE:", round(sse, 2), "\n")
```

```
## SSE: 28.55
```

```
cat("SSR + SSE =", round(ssr + sse, 2), " (debe ser ~ SST)\n")
```

```
## SSR + SSE = 100.56 (debe ser ~ SST)
```

5 Comparación de modelos

```
comparacion <- data.frame(
  Modelo = c("Simple (Female)", "Múltiple (Female + Age + Educ + Parttime)"),
  R2 = c(r2, r2_m),
```

```
R2_ajustado = c(r2_aj, r2_aj_m),
)
comparacion
```

```
##                               Modelo      R2 R2_ajustado
## 1                               Simple (Female) 0.07262172  0.07075951
## 2 M<U+00FA>ltiple (Female + Age + Educ + Parttime) 0.71612392  0.71266904
```

```
n <- nrow(wage)
p_simple <- length(coef(mod_simple))

Cp_simple <- sse / mse_m - (n - 2 * p_simple)
cat("Cp de Mallows (modelo simple):", round(Cp_simple, 2),
    " (p =", p_simple, ")\n")
```

```
## Cp de Mallows (modelo simple): 4    (p = 2 )
```

Conclusión: el modelo múltiple mejora el ajuste (R^2 ajustado de 0.071 a 0.713) y nos permite concluir que la brecha salarial observada entre hombres y mujeres se explica en su mayor parte por diferencias en edad, educación y tipo de. Este es un ejemplo de cómo el MRLM permite ir más allá de una comparación de promedios y aislar el efecto de una variable de interés, manteniendo las demás constantes (interpretación *ceteris paribus*).