

Usando la Estadística para predicción económica

Introducción a las técnicas de Regresión

APUNTES DE CLASE · 2026 · 18 de septiembre de 2026

1 ¿Qué es la Econometría?

Definición Econometría

"La econometría es la rama de la economía que se encarga de contrastar la teoría económica con los métodos cuantitativos y estadísticos con el fin de probar hipótesis que permitan determinar o no la validez de los postulados económicos; así mismo, se encarga de estimar y pronosticar fenómenos económicos." (Iglesias Ibarra y Fernández Rangel, 2022)

Esta disciplina se distingue de la economía teórica porque *cuantifica* las relaciones económicas a partir de datos reales. Mientras la teoría afirma que "la demanda de un bien depende inversamente del precio", la econometría nos permite responder *cuánto* sube o baja la demanda según el precio.

Nota Idea clave

$Econometria = TeoriaEconomica + Matematicas + Estadistica$

La teoría económica nos dice qué relaciones esperar; las matemáticas nos dan el lenguaje formal para expresarlas; y la estadística nos permite validar esas relaciones con los datos reales.

Entonces, si la econometría quiere cuantificar relaciones entre variables económicas, **¿Cómo lo hace? ¿Con qué herramientas lo hace?** Esta rama dispone de un conjunto de herramientas como modelos de series de tiempo, variables cualitativas, estrategias de identificación causal, entre otras. Pero la mayoría de estas técnicas parten de un mismo fundamento: **la Regresión**. Es precisamente de lo que hablaremos ahora.

2 La regresión

Definición Regresión

Una regresión es, en términos generales, una técnica estadística que estudia cómo se relacionan una variable de interés con una o más variables que explican su

comportamiento, con el objetivo de estimar el valor esperado de la primera, dado un conjunto de valores de las segundas.

De forma más intuitiva, supongamos que tienes datos de X e Y , la regresión busca una función que describa cómo varía el promedio de Y a medida que cambia X , pero no busca cualquier función, busca la mejor. No hallamos esta función para predecir el valor exacto de Y , sino más bien para entender la tendencia de la relación entre las variables.

Curiosidad


¿Por qué se llama regresión?

Según Vidakovic (2011), el nombre 'regresión' proviene de Francis Galton, quien estaba analizando las alturas de hijos varones y las alturas promedio de sus padres. Galton observó que los hijos de padres muy altos (o muy bajos) tendían a ser más altos (o más bajos) que el promedio, pero no tanto como sus padres. Analizó que había una tendencia de los valores extremos a regresar.^o acercarse hacia la media poblacional en la siguiente generación. Con el tiempo, la palabra "regresión" pasó a usarse como sinónimo del estudio de la relación funcional entre dos o más variables.

Ejemplo

Educación y Salario

Para ilustrar qué hace una regresión, aquí tenemos un ejemplo con la base CPS1985 (Current Population Survey, 1985), que registra el salario por hora y los años de educación de 534 trabajadores estadounidenses. La pregunta es sencilla: *¿cuánto cambia, en promedio, el salario de un trabajador por cada año adicional de educación?*



Cada punto azul es un dato y la línea negra es la estimación de la regresión (que más adelante veremos cómo se hace). Este ejemplo es importante podemos observar que la recta justo pasa más o menos por la "mitad" de la nube de puntos, es decir, la recta estima el salario **promedio esperado**, condicional a cada nivel de educación, y no el valor puntual que tendrá cada trabajador. Esa es precisamente la idea central de una regresión.

2.1 Forma general

$$Y = f(X_1, X_2, \dots, X_k; \theta) + \varepsilon \tag{1}$$

Donde:

- Y : variable dependiente (respuesta)
- $X_1, \dots, X_k$: variables independientes (regresoras)
- $f(\cdot)$: forma funcional (lineal, logística, etc.)
- θ : parámetros a estimar
- ε : término de error

Nota De forma más rigurosa

Lo que realmente estás modelando es el valor esperado condicional de Y dado X :

$$E[Y \mid X] = f(X; \theta) \tag{2}$$

La regresión no predice el valor exacto de Y para cada observación, sino su promedio dado un valor de X . (ε) es lo que el modelo no puede explicar.

3 Tipos de Regresión

Hasta ahora hemos hablado de la regresión como si solo hubiera una forma de estimarla. La realidad es que la elección del modelo depende de **la naturaleza de la variable respuesta** Y .

Nota Recordatorio: variable aleatoria

Una variable aleatoria es una función que asigna un valor numérico a cada resultado posible de un experimento aleatorio (se conocen los resultados posibles, pero ese resultado no se puede predecir con certeza antes de realizarlo). Estas variables pueden clasificarse según el tipo de valores que toman:

- **Continuas:** toman cualquier valor dentro de un rango (ej. ingreso, precio, PIB).

- **Binarias:** toman solo dos valores, normalmente 0 o 1 (ej. sí/no, aprobado/no aprobado).
- **De conteo:** toman valores enteros no negativos (ej. número de transacciones).
- **Catóricas:** toman un número finito de categorías (ej. sector económico, estrato).

Como Y puede comportarse de varias formas, existen varias formas de modelar. Si asumimos incorrectamente el tipo de variable (por ejemplo, tratar una variable binaria como si fuera continua), el modelo puede arrojar predicciones sin sentido, como probabilidades negativas o mayores a 1.

A continuación, un resumen de los principales tipos de regresión según el tipo de variable respuesta que buscan explicar:

Tipo	$f(X; \theta)$	Y típica	Descripción
Lineal	$\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k$	Continua	Relación aditiva directa entre X y $E[Y \mid X]$.
Logística	$\frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots)}}$	Binaria (0/1)	Transforma la combinación lineal en una probabilidad entre 0 y 1.
Poisson	$e^{\beta_0 + \beta_1 X_1 + \dots}$	Conteos	Garantiza valores esperados no negativos, propios de un conteo.
No paramétrica	Estimada sin forma fija	Cualquiera	No impone una forma funcional; se adapta a los datos.

Nota

Todos estos modelos comparten la misma forma (1), lo que cambia es la forma funcional $f(\cdot)$ y los supuestos sobre la distribución de ε (o directamente sobre Y).

Ahora bien, el tipo de variable respuesta es normalmente el criterio principal para orientar la elección del modelo de regresión, pero no es el único factor. También influyen la forma de la relación entre las variables (lineal o no lineal), la distribución de los errores o de la propia variable respuesta, y el objetivo del análisis (predicción o inferencia causal).

En el análisis económico, las regresiones pueden usarse para estudiar una gran variedad de fenómenos siempre que podamos identificar una variable de interés y otras variables que puedan ayudar a explicar su comportamiento. Por ejemplo, podemos analizar cómo cambia la demanda de un producto cuando cambia su precio, cómo se

relacionan los ingresos de una persona con su nivel de educación y experiencia (Ejemplo anterior), o cómo variables como la inversión, el consumo y el empleo se relacionan con el crecimiento económico. También pueden utilizarse para estudiar fenómenos financieros, como la relación entre las características de una empresa o un cliente y la probabilidad de que incumpla un crédito. En general, como ya se mencionó antes, la regresión permite pasar de una afirmación económica cualitativa, a una relación cuantitativa que se puede estimar utilizando datos reales.

De todos estos modelos, nos concentraremos en dos: el **Modelo de Regresión Lineal Múltiple (MRLM)** y la **regresión logística**.

4 Modelo de Regresión Lineal Múltiple (MRLM)

Este modelo, no solo es el modelo más simple de estimar, sino que sobre él se construyen resultados teóricos fundamentales de la inferencia estadística, como las pruebas de hipótesis sobre los coeficientes, los intervalos de confianza, y los criterios de bondad de ajuste. Entender bien este modelo, es básicamente entender el lenguaje base con el que se construyen todos los demás modelos de regresión.

Recordemos entonces que una regresión busca estimar el valor esperado de una variable de interés (Y) en función de una o más variables que explican su comportamiento (X_j). El **MRLM** es el caso particular en el que se asume que la relación es *lineal* en los parámetros:

Considere el caso en el cual se desea modelar la variabilidad total de una variable respuesta de interés, en función de sus relaciones lineales con dos o más variables predictoras, formuladas simultáneamente en un único modelo. (González Álvarez, 2025)

De una manera más intuitiva: este modelo permite estudiar cómo una variable se relaciona con varias variables que pueden ayudar a explicar su comportamiento. La idea es mantener constantes las demás variables para identificar cuánto cambia, en promedio, la variable de interés cuando una de las variables explicativas cambia. Por ejemplo, podemos estudiar cómo cambia el consumo de los hogares cuando aumenta su ingreso, teniendo en cuenta también otras variables como el tamaño del hogar o precios.

4.1 Notación

Para n observaciones, el MRLM se escribe como:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + \varepsilon_i, \quad i = 1, \dots, n \quad (3)$$

Donde:

- Y_i : valor observado de la variable respuesta en la observación i .

- $X_{i1}, X_{i2}, \dots, X_{ik}$: valores observados de las k variables predictoras en la observación i .
- β_0 : intercepto (valor esperado de Y cuando todas las $X_j = 0$).
- $\beta_1, \dots, \beta_k$: coeficientes de regresión (β_j mide el cambio esperado en Y por un cambio unitario en X_j , *manteniendo las demás variables constantes* (interpretación *ceteris paribus*)).
- ε_i : término de error de la observación i (todo lo que las variables predictoras no logran explicar).
- n : número total de observaciones; k : número de variables predictoras.

4.2 Notación matricial

$$Y = X\beta + \varepsilon \quad (4)$$

Donde:

- Y : vector columna de tamaño $n \times 1$ con las observaciones de la variable respuesta.

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}$$

- X : matriz de diseño de tamaño $n \times (k+1)$, que contiene una columna de unos (para el intercepto) y una columna por cada variable predictora.

$$X = \begin{pmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1k} \\ 1 & X_{21} & X_{22} & \cdots & X_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{nk} \end{pmatrix}$$

- β : vector columna de tamaño $(k+1) \times 1$ con los parámetros a estimar.

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}$$

- ε : vector columna de tamaño $n \times 1$ con los errores de cada observación.

$$\varepsilon = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

4.3 Supuestos del modelo

Hasta ahora hemos escrito el modelo y teóricamente sabemos todo lo que tiene, pero en la práctica los verdaderos parámetros β son **desconocidos** (es precisamente lo que no sabemos y queremos averiguar a partir de los datos). Nuestro objetivo es entonces hallar una **estimación** para β , buscando que se aproxime lo mejor posible a los valores reales. Para que esa estimación sea posible y *confiable*, el modelo debe cumplir con los siguientes supuestos:

Supuesto sobre las variables predictoras:

- **No multicolinealidad perfecta:** las predictoras no deben guardar una asociación lineal fuerte entre sí; cada una debe aportar información *independiente* al modelo. Matemáticamente, esto equivale a que las columnas de la matriz X sean LI, es decir, que $\det(X^T X) \neq 0$.

Nota ¿Por qué $\det(X^T X) \neq 0$ y no $\det(X) \neq 0$?

El determinante está definido para matrices **cuadradas**. Como X tiene n filas (observaciones) y $k+1$ columnas (variables), y casi siempre hay muchas más observaciones que variables, X **no siempre es cuadrada**. En cambio, $X^T X$ **siempre es cuadrada** ($(k+1) \times (k+1)$). Y resulta que $X^T X$ es invertible ($\det \neq 0$) cuando las columnas de X son LI.

Teorema $X^T X$ es invertible $\iff$ columnas de X son LI

Sea X una matriz de tamaño $n \times (k+1)$ con columnas linealmente independientes. Entonces $X^T X$ es invertible.

Demostración. Basta mostrar que el espacio nulo de $X^T X$ es trivial, es decir, que $X^T X v = 0 \implies v = 0$.

Supongamos que $X^T X v = 0$. Multiplicando ambos lados por v^T :

$$v^T X^T X v = 0$$

Entonces $v^T X^T X v = (Xv)^T (Xv) = \|Xv\|^2$, de ahí

$$\|Xv\|^2 = 0 \implies Xv = 0$$

Como las columnas de X son LI, la única solución de $Xv = 0$ es $v = 0$. Por tanto, $X^T X v = 0$ implica $v = 0$, es decir, $X^T X$ tiene espacio nulo trivial y es invertible. ■

Supuestos sobre el término de error:

$$\varepsilon_i \stackrel{\text{iid}}{\sim} N(0, \sigma^2) \quad (5)$$

Esta única expresión encierra, de hecho, cuatro supuestos distintos:

- **Media cero:** $E[\varepsilon_i] = 0$ para todo i . En promedio, el error no sobreestima ni subestima sistemáticamente a Y .
- **Normalidad:** ε_i sigue una distribución normal. Esto permite realizar las pruebas de hipótesis e intervalos de confianza sobre los coeficientes.
- **Homocedasticidad:** $\text{Var}(\varepsilon_i) = \sigma^2$ (constante) para todo i . La dispersión del error es la misma sin importar los valores que tomen las X ; el modelo no es más preciso para unas observaciones que para otras.
- **Independencia (no autocorrelación):** $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ para todo $i \neq j$. El error de una observación no contiene información sobre el error de otra.

4.4 Estimación de los parámetros

¿Cómo hallamos $\hat{\beta}$ a partir de los datos? Existen varias técnicas estadísticas para estimar parámetros desconocidos de un modelo; dos de las más importantes son:

- **Mínimos Cuadrados Ordinarios (MCO):** busca los valores de β que *minimizan* la suma de los errores al cuadrado entre los valores observados y los predichos por el modelo.
- **Máxima Verosimilitud (MV):** busca los valores de β que hacen *más probable* haber observado los datos que efectivamente observamos, dado el supuesto sobre la distribución de los errores. (Maximiza la Función de verosimilitud)

Bajo los supuestos mencionados anteriormente, ambas técnicas llegan al mismo estimador $\hat{\beta}$. Sin entrar en detalles de cálculo, el estimador para β es:

$$\hat{\beta} = (X^T X)^{-1} X^T Y \quad (6)$$

Nota ¿Por qué necesitábamos el supuesto de antes?

Si las columnas de X no son LI, la matriz $X^T X$ no es invertible y **no existe una solución única** para $\hat{\beta}$ (el modelo no se podría estimar).

4.5 Comentarios finales

- **Interpretación de los coeficientes.** Cada $\hat{\beta}_j$ se interpreta como el cambio esperado en Y ante un aumento de una unidad en X_j manteniendo las demás variables constantes. El signo indica la dirección del efecto (positivo o negativo), y la magnitud indica qué tan grande es ese efecto en las unidades de Y . El intercepto $\hat{\beta}_0$ se interpreta como el valor esperado de Y cuando todas las predictoras son cero (si es que tiene sentido práctico que $X = 0$).
- **El modelo no sirve para extrapolar.** Este modelo se estima usando el rango de valores observados de las predictoras; fuera de ese rango, no tenemos garantía de que la relación lineal estimada se siga cumpliendo. Predecir Y para valores de X alejados de los datos con los que se entrenó el modelo es arriesgado y posiblemente erróneo.

- **"Lineal"** se refiere a los **parámetros**, no a las **variables**. Que el modelo sea *lineal* significa que es lineal en β , no que la relación entre X y Y sea lineal. Podemos incluir términos como X^2 , $\log(X)$ o $X_1 X_2$ como predictoras, y el modelo sigue siendo lineal, aunque la superficie de regresión resultante tenga curvatura.
- **Sensibilidad a valores atípicos**. Como MCO minimiza errores *al cuadrado*, observaciones atípicas (*outliers*) pueden tener mucha influencia sobre $\hat{\beta}$, es importante revisar los datos.

5 Regresión logística

En el modelo anterior, la variable respuesta Y era continua. Pero, en la práctica hay un caso muy común en el que Y es **binaria**: un cliente paga o no paga un crédito, un producto sale defectuoso o no, etc. En estos casos, no tiene mucho sentido preguntarse ¿cuánto vale Y en promedio? pues Y solo puede ser 0 o 1; lo que sí tiene sentido, es **qué tan probable** es que ocurra ($Y = 1$) dadas ciertas características. Por eso el problema deja de ser modelar Y y pasa a ser **modelar la probabilidad de éxito** $\theta_i = P(Y_i = 1 | x_i)$, y así tenemos toda la información que necesitamos sobre el comportamiento de Y . Este cambio de enfoque es precisamente lo que da origen a la regresión logística.

La regresión logística es un modelo de regresión para variables respuesta binarias, en el cual la probabilidad de éxito $\theta_i = P(Y_i = 1 | x_i)$ se relaciona con un conjunto de predictoras a través de una combinación lineal, transformada mediante la función de enlace *logit*, de forma que las probabilidades estimadas queden acotadas entre 0 y 1.

5.1 Notación

Nota Recordatorio: distribución Bernoulli

Recordemos que una **función de masa de probabilidad** es una fórmula que nos dice qué tan probable es cada valor que puede tomar una variable aleatoria discreta. La distribución Bernoulli es la más simple de todas y describe una variable Y que solo puede tomar dos valores, 0 (fracaso) o 1 (éxito), con probabilidad de éxito θ :

$$f(y | \theta) = \theta^y (1 - \theta)^{1-y}, \quad y \in \{0, 1\}$$

Entonces si $y = 1$: $f(1 | \theta) = \theta$; y si $y = 0$: $f(0 | \theta) = 1 - \theta$. Su media y varianza son:

$$E[Y] = \theta, \quad \text{Var}(Y) = \theta(1 - \theta)$$

Supongamos que queremos estudiar si una empresa incumple o no un crédito. Tenemos n empresas, y para cada una observamos $Y_i = 1$ si incumplió y $Y_i = 0$ si no. Lo más simple que podríamos hacer es calcular $\hat{\theta} = \bar{Y}$, es decir, la proporción de empresas que incumplieron en la muestra, esto nos daría **un solo número** que nos dice la

probabilidad promedio de incumplimiento para *cualquier* empresa (sin distinción).

Pero esto ignora que, si por ejemplo, tenemos una empresa muy endeudada y con pocas ganancias, esta no tiene la misma probabilidad de incumplir que una empresa financieramente estable y rentable. Entonces por eso nos interesa una probabilidad de incumplimiento **distinta para cada empresa**, que dependa de sus propias características (liquidez, rentabilidad, etc.). En términos formales:

$$Y_i | x_i \sim \text{Bernoulli}(\theta_i), \quad \theta_i = P(Y_i = 1 | x_i) \quad (7)$$

Cada empresa i tiene su **propio** θ_i , en vez de compartir un único θ con las demás.

Ahora, ¿cómo hacemos que θ_i dependa de las características x_i de cada empresa? se toma la misma idea del MRLM: combinamos esas características linealmente. Pero no podemos igualar esa combinación lineal directamente a θ_i (recordemos que $\theta_i \in [0, 1]$), así que la conectamos a través de una función de enlace $g(\cdot)$:

$$g(\theta_i) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} \quad (8)$$

Nota ¿Por qué usar una función de enlace?

Si tomáramos $g(\theta_i) = \theta_i$ (como en el MRLM), el predictor lineal puede tomar valores negativos o mayores que 1, y θ_i , al ser una probabilidad, pertenece a $[0, 1]$. Necesitamos una función $g(\cdot)$ que lleve cualquier valor real hacia ese rango.

5.2 La función de enlace logit

La función que usa la regresión logística es la función **logit**:

$$\text{logit}(\theta_i) = \ln \left(\frac{\theta_i}{1 - \theta_i} \right) = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} \quad (9)$$

El cociente $\psi(x_i) = \frac{\theta_i}{1 - \theta_i}$ se conoce como **razón de probabilidades** u **odds ratio (OR)** (probabilidad de éxito dividida entre la probabilidad de fracaso). La función logit es, entonces, el logaritmo de esa razón.

¿Por qué logit?


Recordemos que el problema es que el predictor lineal $z_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik}$ puede tomar **cualquier valor real**, pero necesitamos que θ_i sea siempre una probabilidad, es decir, un número entre 0 y 1. El logit resuelve exactamente ese problema.

La función logit, $\ln \left(\frac{\theta_i}{1 - \theta_i} \right)$, toma un número en $(0, 1)$ y lo estira hacia toda la recta real: cuando θ_i se acerca a 0, el logit tiende a $-\infty$; cuando θ_i se acerca a 1, el logit tiende a $+\infty$; y cuando $\theta_i = 0,5$, el logit es exactamente 0. Como esta fun-

cion es **invertible**, se puede despuejar θ_i de la ecuación, y obtenemos la función **logística**, que hace justo lo contrario y comprime cualquier número real de vuelta al intervalo $(0, 1)$ —:

$$\theta_i = \frac{e^{z_i}}{1 + e^{z_i}}, \quad z_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_k x_{ik} \quad (10)$$

Esta función logística se ve de la siguiente manera:



Esta curva nunca toca 0 ni 1, así θ_i siempre queda estrictamente dentro del rango válido de una probabilidad. La función es creciente, lo que quiere decir que entre más grande sea el predictor lineal z_i , mayor es la probabilidad estimada θ_i .

5.3 Supuestos del modelo

- **Distribución Bernoulli:** cada Y_i sigue una distribución Bernoulli(θ_i).
- **Independencia:** las observaciones $Y_1, \dots, Y_n$ son independientes entre sí.
- **Linealidad en el logit:** el logaritmo de la razón de probabilidades es una función lineal de las predictoras.
- **No multicolinealidad:** al igual que en el MRLM, las columnas de la matriz de diseño X deben ser LI para que exista una única combinación de parámetros que explique los datos y no varias igual de válidas.

Nota ¿Por qué aquí no hay supuestos sobre el error?

En el MRLM, la varianza del error (σ^2) es un número desconocido y toca estimarlo aparte, por eso necesitábamos supuestos (homocedasticidad, etc.) que nos dijeran cómo se debía comportar ese error.

En la regresión logística esto no aplica, porque Y_i es una variable Bernoulli, y en una Bernoulli la varianza depende completamente de θ_i ,

$$\text{Var}(Y_i) = \theta_i(1 - \theta_i).$$

Y si ya sabemos cuál es la probabilidad θ_i , automáticamente sabemos cuál es la varianza, no hay nada más que estimar, ni ningún supuesto extra que imponer al error, porque no es un error 'separado' como lo era en el MRLM.

5.4 Estimación de los parámetros

Al igual que en el MRLM, los parámetros β son desconocidos y debemos estimarlos a partir de los datos. Se usa la estimación por **Máxima Verosimilitud**, ya que **no existe una fórmula cerrada** para $\hat{\beta}$.

Partiendo del modelo Bernoulli para cada observación, la función de verosimilitud conjunta es:

$$L(\beta) = \prod_{i=1}^n \theta_i^{y_i} (1 - \theta_i)^{1-y_i}, \quad \text{donde } \theta_i = \frac{e^{x_i^T \beta}}{1 + e^{x_i^T \beta}} \quad (11)$$

y buscamos el vector $\hat{\beta}$ que la maximiza:

$$\hat{\beta} = \arg \max_{\beta \in \mathbb{R}^p} L(\beta), \quad p = k + 1 \quad (12)$$

Nota ¿Por qué no hay solución cerrada?

En el MRLM, minimizar la suma de errores al cuadrado nos lleva a un sistema de ecuaciones *lineal* en β , que se resuelve algebraicamente: $\hat{\beta} = (X^T X)^{-1} X^T Y$. Aquí, θ_i depende de β de forma *no lineal* (a través de la función logística), así que $L(\beta)$ tampoco es lineal en β . No hay forma de despejar $\hat{\beta}$ algebraicamente; se encuentra **numéricamente**, mediante algoritmos de optimización como Newton-Raphson o mínimos cuadrados iterativamente reponderados. En la práctica, esto se puede hacer con la función `glm()` de R.

Cuando tenemos suficientes datos, $\hat{\beta}$ se comporta aproximadamente como una distribución normal:

$$\hat{\beta} \overset{\text{aprox}}{\sim} N_p(\beta, V), \quad V = I^{-1} \quad (13)$$

Esto es útil porque nos permite calcular errores estándar, intervalos de confianza y pruebas de hipótesis para cada $\hat{\beta}_j$ como en el MRLM.

5.5 Comentarios finales

- **Interpretación de los coeficientes.** A diferencia del MRLM, $\hat{\beta}_j$ **no** se interpreta como el cambio esperado en Y , porque Y ya no es continua. Lo que sí tiene una interpretación directa es su exponencial. Recordemos que $\ln(\psi(x_j)) = \beta_0 + \dots + \beta_j x_j + \dots$; si aumentamos x_j en una unidad y restamos:

$$\ln(\psi(x_j + 1)) - \ln(\psi(x_j)) = \beta_j \implies \ln\left(\frac{\psi(x_j + 1)}{\psi(x_j)}\right) = \beta_j$$

Aplicando exponencial a ambos lados, obtenemos:

$$\exp(\hat{\beta}_j) = \frac{\psi(x_j + 1)}{\psi(x_j)}$$

En conclusión, la ecuación anterior es un cociente de las chances de éxito *después* de aumentar X_j en una unidad, divididas entre las chances de éxito *antes* de aumentar X_j . Entonces su valor nos dice directamente si las chances crecieron, se redujeron o se mantuvieron igual:

- Si $\exp(\hat{\beta}_j) > 1$: las chances 'después' son mayores que las chances 'antes' → aumentan las chances de éxito.
- Si $\exp(\hat{\beta}_j) < 1$: las chances 'después' son menores que las chances 'antes' → disminuyen las chances de éxito.
- Si $\exp(\hat{\beta}_j) = 1$ ($\hat{\beta}_j = 0$): las chances 'después' son iguales a las de 'antes' → la variable no tiene efecto.

Es común expresar este cambio en términos porcentuales:

$$(\exp(\hat{\beta}_j) - 1) \times 100 \%$$

Por ejemplo, si $\exp(\hat{\beta}_j) = 1,5$, quiere decir que las chances de éxito después del incremento son 1.5 veces las chances de antes, es decir, un 50 % más grandes.

- **El modelo entrega probabilidades, no clases.** La salida del modelo es $\hat{\theta}_i \in (0, 1)$; convertir eso en una clasificación binaria es una decisión adicional, y el umbral de corte puede ajustarse de forma conveniente.

6 Evaluación y Comparación de Modelos

En la práctica, lo usual es plantear **varios modelos candidatos**, con distintos subconjuntos de variables predictoras, distintas transformaciones, o incluso distintas formas funcionales y luego se evalúa **¿Qué tan bien se ajusta un modelo a los datos?** y **¿Cuál de los modelos candidatos deberíamos preferir?**


Para esto, la estadística recurre a **algoritmos de selección**, que exploran distintos subconjuntos de variables y a **métricas** que resumen qué tan bueno es un modelo. Algunas de estas métricas aplican a cualquier tipo de regresión y otras están diseñadas específicamente para el tipo de variable respuesta que se está modelando.

Nota Descomposición de la varianza y MSE

Para el MRLM, casi todas las métricas de evaluación se construyen a partir de tres cantidades que descomponen la variabilidad total de Y :

- $SST = \sum_i (Y_i - \bar{Y})^2$: variabilidad **total** de Y alrededor de su media.
- $SSR = \sum_i (\hat{Y}_i - \bar{Y})^2$: la parte de esa variabilidad que el modelo **logra explicar**.

- $SSE = \sum_i (Y_i - \hat{Y}_i)^2$: la parte que **no** logra explicar (los residuos), tal que $SST = SSR + SSE$.



El **MSE** (*Mean Squared Error*) es simplemente SSE dividido por sus grados de libertad, $MSE = SSE / (n - p)$ (estimador de σ^2 , la varianza del error)

6.1 Métricas de evaluación

Para el MRLM

- **R^2 (coeficiente de determinación)**: responde a "¿qué proporción de la variabilidad total de Y logra explicar mi modelo?"

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}, \quad R^2 \in [0, 1]$$

- **Prueba F (significancia general)**: responde a "¿el explica algo, o ninguna de mis variables predictoras sirve?"

$$H_0 : \beta_1 = \dots = \beta_k = 0 \text{ vs. } H_1 : \text{algún } \beta_j \neq 0, \quad F = \frac{SSR/k}{SSE/(n-k-1)} \sim F_{k, n-k-1}$$

- **Prueba t (significancia individual)**: responde a "¿esta variable en particular aporta algo?"

$$H_0 : \beta_j = 0 \text{ vs. } H_1 : \beta_j \neq 0, \quad t = \frac{\hat{\beta}_j}{\widehat{se}(\hat{\beta}_j)} \sim t_{n-p}$$

Para la regresión logística

Como Y ya no es continua, no aplican R^2 , SST/SSE ni las pruebas F/t de arriba. En su lugar, evaluamos qué tan bien el modelo **clasifica** las observaciones.

Nota ¿Con qué datos se evalúa?

En clasificación es práctica común **dividir la muestra** en un conjunto de *entrenamiento* (usado para ajustar el modelo) y uno de *prueba* (usado únicamente para evaluarlo). Todas las métricas que siguen se calculan idealmente sobre el conjun-

to de **prueba**, es decir, sobre observaciones que el modelo **no vio** al momento de ajustarse.

Matriz de confusión

Comparamos las clases predichas (usando un umbral sobre $\hat{\theta}_i$, típicamente 0.5) contra las clases reales:


		Predicho	
		Éxito (1)	Fracaso (0)
Real	Éxito (1)	VP	FN
	Fracaso (0)	FP	VN

- **TCC (Tasa de Clasificación Correcta)**: proporción de observaciones bien clasificadas en total,

$$TCC = \frac{VP + VN}{n}$$

Puede ser engañosa con clases desbalanceadas (ej. si solo 2% incumple, predecir siempre "no incumpleza da 98% de TCC, sin ser útil).

- **Curva ROC y AUC**: El TCC depende de haber fijado **un solo umbral** de corte (usualmente 0.5) para decidir si clasificamos como éxito o fracaso. La curva ROC resuelve este problema evaluando al modelo en **todos** los umbrales posibles a la vez. Para cada umbral posible, se calculan dos cantidades y se grafican una contra la otra: La tasa de verdaderos positivos, es decir, qué tan bien detecta los éxitos reales (eje Y) contra la tasa de falsos positivos o cuántos fracasos termina clasificando erróneamente como éxito (eje X).



- Un modelo **bueno** tiene una curva que se acerca hacia la esquina superior izquierda: detecta muchos verdaderos positivos generando pocos falsos positivos.

Como comparar curvas completas es tedioso, se resume toda esa información en un solo número: el **AUC** (*Area Under the Curve*), el área bajo la curva ROC.

6.2 Criterios de comparación y selección de modelos

Cuando tenemos varios modelos candidatos, necesitamos criterios que penalicen la complejidad, porque un modelo con más variables casi siempre ajusta mejor a los mismos datos, pero no queremos sobreajuste.

- **R^2 ajustado**: corrige el problema de R^2 (que nunca baja al agregar variables) penalizando por el número de parámetros p :

$$R^2_{aj} = 1 - \frac{SSE/(n-p)}{SST/(n-1)}$$

Esta métrica solo aumenta si la variable nueva aporta más de lo que "cuesta" en complejidad.

- **C_p de Mallows**: la idea es comparar el error de un modelo *reducido* (con p parámetros) contra el error del modelo *completo* (con todas las variables), usando este último como referencia de "qué tan bien se puede llegar a ajustar"

$$C_p = \frac{SSE_p}{\widehat{MSE}_{\text{completo}}} - (n - 2p)$$

Se buscan modelos donde $C_p \approx p$ y se descartan aquellos donde $C_p \gg p$.

Nota ¿Por qué se busca $C_p \approx p$?

Si al modelo reducido no le falta ninguna variable importante, su SSE_p es prácticamente igual al del modelo completo, es decir, $SSE_p \approx (n-p) \cdot \widehat{MSE}_{\text{completo}}$. Al reemplazar esto en la fórmula de C_p , el primer término queda aproximadamente en $n-p$, y al restarle $(n-2p)$ obtenemos:

$$C_p \approx (n-p) - (n-2p) = p$$

Es decir, el $-(n-2p)$ es una corrección para que en el caso "ideal" (sin variables faltantes), todo se cancele y quede $C_p \approx p$. Si en cambio al modelo reducido sí le faltan variables significativas, SSE_p es más grande de lo que esa aproximación predice, y C_p se va muy por encima de p .

- **$PRESS_p$** : mide qué tan bien predice el modelo observaciones que **no se usaron** para estimarlo (se reajusta el modelo dejando cada observación i por fuera, se mide su error de predicción $e_{(i)}$, y se suman al cuadrado):

$$PRESS_p = \sum_{i=1}^n e_{(i)}^2$$

7 Ejemplos Prácticos

Ejemplo Modelo MRLM

Datos. Muestra de 500 empleados (país, sector y año fijos). Variable respuesta: $\log(\text{Wage}_i)$. Predictoras: *Female*, *Age*, nivel educativo (*Educ*, categórica con dummies *DE2*, *DE3*, *DE4*) y *Parttime*.

¿Por qué $\log(\text{Wage})$? Los salarios están sesgados a la derecha; el logaritmo simetriza la distribución (acercándola al supuesto de normalidad del MRLM) y permite interpretar los coeficientes de variables dummy directamente como **cambios porcentuales** en el salario: $\%\Delta\text{Wage} \approx 100 \times \hat{\beta}$.

Modelo simple:

$$\log(\text{Wage}_i) = \beta_0 + \beta_1 \text{Female}_i + \varepsilon_i$$

Modelo múltiple:

$$\log(\text{Wage}_i) = \beta_0 + \beta_1 \text{Female}_i + \beta_2 \text{Age}_i + \beta_3 \text{DE2}_i + \beta_4 \text{DE3}_i + \beta_5 \text{DE4}_i + \beta_6 \text{Parttime}_i + \varepsilon_i$$

Estimación. Ambos modelos se ajustan por Mínimos Cuadrados Ordinarios (MCO), resolviendo $\hat{\beta} = (X^T X)^{-1} X^T Y$.

Modelo simple	Estimate	Std. Error	t value	Pr(> t)
Intercepto	4.7336	0.0243	194.45	< 0,001
Female	-0,2506	0.0401	-6,24	< 0,001

Modelo múltiple	Estimate	Std. Error	t value	Pr(> t)
Intercepto	3.3180	0.0514	64.55	< 0,001
Female	-0,0308	0.0244	-1,27	0.206
Age	0.0304	0.0013	24.27	< 0,001
Educ = 2	0.1706	0.0270	6.31	< 0,001
Educ = 3	0.3805	0.0293	13.00	< 0,001
Educ = 4	0.7655	0.0354	21.61	< 0,001
Parttime	-0,3659	0.0310	-11,81	< 0,001

Interpretación económica. En el modelo simple, las mujeres ganan en promedio un 22.2 % menos que los hombres (*brecha bruta*), diferencia estadísticamente significativa. Al incluir edad, educación y tipo de jornada, la brecha se reduce a solo 3.1 % y **deja de ser significativa** (p-valor = 0,206). Es decir: gran parte de la diferencia salarial observada no se explica por el género en sí, sino por que hombres y mujeres difieren en otras características que también afectan el salario.

Comparación de modelos. El R^2 ajustado pasa de 0.071 (modelo simple) a 0.713 (modelo múltiple), y el C_p de Mallows del modelo simple resulta muy superior a su número de parámetros (le faltan variables relevantes).

Ejemplo Modelo de Regresión Logística

Datos. Base *Default* (ISLR): 10,000 clientes de tarjetas de crédito. Variable respuesta binaria: *default* (1 = incumplió, 0 = no incumplió; solo 3.3 % de la muestra incumple). Predictoras: *balance* (deuda), *income* (ingreso) y *student* (si es estudiante).

Modelo simple:

$$\text{logit}(\theta_i) = \ln\left(\frac{\theta_i}{1 - \theta_i}\right) = \beta_0 + \beta_1 \text{balance}_i$$

Modelo múltiple:

$$\text{logit}(\theta_i) = \beta_0 + \beta_1 \text{balance}_i + \beta_2 \text{income}_i + \beta_3 \text{student}_i$$

Estimación. Al no existir fórmula cerrada, $\hat{\beta}$ se estima por Máxima Verosimilitud (algoritmo IRLS/Newton-Raphson), maximizando la probabilidad de haber observado los datos reales.

Modelo simple	coef	std err	z	P(> z)
Intercepto	-10,7134	0.435	-24,60	< 0,001
balance	0.0055	0.000	20.88	< 0,001

Modelo múltiple	coef	std err	z	P(> z)
Intercepto	-11,0223	0.594	-18,56	< 0,001
balance	0.0058	0.000	20.63	< 0,001
income	$4,19 \times 10^{-6}$	$9,73 \times 10^{-6}$	0.43	0.667
student	-0,7234	0.282	-2,57	0.010

Interpretación económica. En el modelo simple, cada unidad adicional de balance de deuda(deuda) multiplica las chances de incumplir por $OR = 1,0055$ (un 0.55 % más, por cada dólar de deuda adicional). En el modelo múltiple, ser estudiante reduce las chances de incumplir en cerca de un 52 % ($OR = 0,485$, significativo), mientras que *income* no resulta significativa, sugiriendo que el nivel de endeudamiento explica el riesgo de impago mucho mejor que el ingreso.

Comparación de modelos. Evaluados sobre un conjunto de prueba (30 % de los datos, no usado para ajustar): la Tasa de Clasificación Correcta (TCC) sube de 97.30 % a 97.53 %, y el AUC de 0.9386 a 0.9396 al pasar del modelo simple al múltiple. La mejora es real pero muy pequeña: el balance de deuda es un predictor muy fuerte del riesgo de impago.

8 Comentarios

- En economía, muchas de las variables se observan a lo largo del tiempo: el PIB, la inflación, el desempleo, las tasas de interés, las ventas, etc. Esto hace que las observaciones puedan estar relacionadas con las de períodos anteriores. Aquí, un MRLM puede que no sea la herramienta adecuada (por los supuestos de independencia de los errores). Por ello, suele ser más conveniente utilizar modelos de series de tiempo u otras técnicas que tengan en cuenta la dinámica de las variables.

9 Bibliografía

Cardona Jiménez, J. (2026). *Estadística II* [notas de clase]. Departamento de Estadística, Universidad Nacional de Colombia, Sede Medellín.

González Álvarez, N. (2025). *Notas de Clase Estadística III 3009137. Capítulo 2: Repaso regresión lineal múltiple (MRLM)*. Departamento de Estadística, Universidad Nacional de Colombia, Sede Medellín.

Iglesias Ibarra, A. J., y Fernández Rangel, J. A. (2022). *Introducción a la econometría: teoría y aplicaciones usando Stata 17*. Bogotá: Fundación Universitaria del Área Andina.

Universidad Erasmus de Róterdam. *Erasmus Econometrics* [curso en línea]. Coursera. Recuperado de <https://www.coursera.org/learn/erasmus-econometrics>

Vidakovic, B. (2011). Regression. En *Statistics for Bioengineering Sciences* (pp. 599–600). Springer Texts in Statistics. Springer, New York, NY. https://doi.org/10.1007/978-1-4614-0394-4_16

Anthropic. (2026). *Claude* (Sonnet 4.5) [modelo de lenguaje de gran escala]. <https://claude.ai>