

Regresión Lineal Simple – Base de datos CPS1985

Parte práctica: Introducción a la Econometría — Modelos de Regresión

16 de septiembre de 2026

Contents

1	Datos	1
2	Ajuste del modelo: Regresión Lineal Simple	2
2.1	Pruebas de hipótesis	3
2.2	Métricas de evaluación	3

1 Datos


Usamos la base CPS1985 (*Current Population Survey*, 1985), que contiene información salarial de 534 trabajadores en Estados Unidos. La cargamos directamente desde el repositorio Rdatasets.

```
cps <- read.csv(
  ↪ "https://raw.githubusercontent.com/vincentarelbundock/Rdatasets/master/csv/AER/CPS1985.csv")
str(cps)
```

```
## 'data.frame':    534 obs. of  12 variables:
## $ rownames      : int  1 1100 2 3 4 5 6 7 8 9 ...
## $ wage          : num  5.1 4.95 6.67 4 7.5 ...
## $ education     : int  8 9 12 12 12 13 10 12 16 12 ...
## $ experience    : int  21 42 1 4 17 9 27 9 11 9 ...
## $ age          : int  35 57 19 22 35 28 43 27 33 27 ...
## $ ethnicity     : chr  "hispanic" "cauc" "cauc" "cauc" ...
## $ region        : chr  "other" "other" "other" "other" ...
## $ gender        : chr  "female" "female" "male" "male" ...
## $ occupation    : chr  "worker" "worker" "worker" "worker" ...
## $ sector        : chr  "manufacturing" "manufacturing" "manufacturing" "other" ...
## $ union         : chr  "no" "no" "no" "no" ...
## $ married       : chr  "yes" "yes" "no" "no" ...
```

Nuestra variable respuesta (Y) será `wage` (salario por hora, en dólares). Como predictora usaremos `education` (años de educación). Aquí un gráfico de cómo se ve la nube de puntos:

```
plot(cps$education, cps$wage,
     xlab = "Educación (años)", ylab = "Salario por hora (USD)",
     main = "Relación entre educación y salario",
     pch = 19, col = rgb(0, 0, 1, 0.3))
```



2 Ajuste del modelo: Regresión Lineal Simple

Empezamos con el modelo más simple: explicar el salario únicamente a partir de los años de educación.

$$\text{wage}_i = \beta_0 + \beta_1 \cdot \text{education}_i + \varepsilon_i$$

```
mod_simple <- lm(wage ~ education, data = cps)
summary(mod_simple)
```

```
##
## Call:
## lm(formula = wage ~ education, data = cps)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.911  -3.260  -0.760   2.240  34.740
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.74598    1.04545  -0.714    0.476
## education    0.75046    0.07873   9.532 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.754 on 532 degrees of freedom
## Multiple R-squared:  0.1459, Adjusted R-squared:  0.1443
## F-statistic: 90.85 on 1 and 532 DF, p-value: < 2.2e-16
```

2.1 Pruebas de hipótesis

El resumen anterior ya incluye la **prueba t** de significancia individual para β_1 y la **prueba F** de significancia general (en este caso equivalentes, al haber una sola predictora).

```
confint(mod_simple)
```

```
##              2.5 %    97.5 %  
## (Intercept) -2.7997043 1.3077449  
## education    0.5957936 0.9051279
```

2.2 Métricas de evaluación

```
r2 <- summary(mod_simple)$r.squared  
r2_aj <- summary(mod_simple)$adj.r.squared  
mse <- mean(residuals(mod_simple)^2)
```

```
cat("R^2:", round(r2, 4), "\n")
```

```
## R^2: 0.1459
```

```
cat("R^2 ajustado:", round(r2_aj, 4), "\n")
```

```
## R^2 ajustado: 0.1443
```

```
cat("MSE:", round(mse, 4), "\n")
```

```
## MSE: 22.5157
```

```
plot(cps$education, cps$wage,  
     xlab = "Educación (años)", ylab = "Salario por hora (USD)",  
     pch = 19, col = rgb(0, 0, 1, 0.3))  
abline(mod_simple, col = "black", lwd = 2)
```

